

Mini-Challenge 1: Activity Recognition mit MLP

Ziel

Implementiere, trainiere und validiere ein MLP-Modell für die Klassifikation von Bewegungsdaten ([Activity Recognition Dataset](#)). Es gibt geeignetere Modelle, um Sequenz-Daten zu repräsentieren und klassifizieren (wie z.B. RNNs). Dennoch wollen wir es hier mit einem MLP versuchen, um nachher bei der Behandlung der RNNs auch eine gute Vergleichsbasis zu haben.

Arbeitsschritte

Schritt 1: Daten Kennenlernen

1. Implementiere Funktionalität, um den Datensatz zu laden.
2. Mache Dich mit dem Datensatz vertraut, indem Du eine explorative Analyse der Features durchführst: z.B. Vergleich der Klassen pro Feature, Balanciertheit der Klassen.
3. Führe ein geeignetes Preprocessing durch: Normalisierung der Daten.

Schritt 2: Aufbau Modellierung

4. Lege fest, wie (mit welchen Metriken) Du die Modelle evaluieren möchtest. Berücksichtige auch den Fehler in der Schätzung dieser Metriken.
5. Implementiere Basisfunktionalität, um beliebige MLP Modelle zu trainieren und gegeneinander zu evaluieren. Wie sollen die Gewichte initialisiert werden?

Schritt 3: Training mit SGD, ohne REG, ohne BN

6. Untersuche MLP-Modelle unterschiedlicher Komplexität, welche geeignet sein könnten, um das Klassifikationsproblem zu lösen. Verwende Stochastic Gradient Descent. Verwende noch keine Regularisierung (REG) und keine Batchnorm (BN).
 - a. Für jedes MLP mit gegebener Anzahl Layer und Units pro Layer führe ein sorgfältiges Hyper-Parameter-Tuning durch (Lernrate, Batch-Grösse). Achte stets darauf, dass das Training stabil verläuft. Merke Dir bei jedem Training, den Loss, die Performance Metrik(en) inkl. Schätzfehler, die verwendete Anzahl Epochen, Lernrate und Batch-Grösse.
 - b. Variiere die Anzahl Layer und Anzahl Units pro Layer, um eine möglichst gute Performance zu erreichen.
 - c. Fasse die Ergebnisse zusammen in einem geeigneten Plot, bilde eine Synthese und folgere, welche Modell-Komplexität Dir am sinnvollsten erscheint.

Schritt 4: Nutzen der Regularisierung

7. Ziehe nun verschiedene Regularisierungsmethoden in Betracht:
 - a. L1/L2 Weight Penalty
 - b. DropoutAnsonsten folge denselben Schritten wie in 6.
8. Evaluiere den Nutzen der Regularisierung, auch unter Berücksichtigung verschiedener Regularisierungsstärken. Beschreibe auch kurz, was allgemein das Ziel von Regularisierungsmethoden ist (Regularisierung im Allgemeinen, sowie auch Idee der einzelnen Methoden). Inwiefern wird dieses Ziel im gegebenen Fall erreicht?

Schritt 5: Nutzen von Batchnorm BN (ohne REG, mit SGD)

9. Evaluiere, ob Batchnorm etwas bringt.

Schritt 6: Nutzen von Adam (ohne BN, ohne / mit REG)

10. Evaluiere, ob Du mit Adam bessere Resultate erzielen kannst.
11. Versuche den erreichten / nicht erreichten Nutzen zu interpretieren.

Arbeitsschritte

Alle Schritte sollen in einem *gut strukturierten* und *gut dokumentierten* Jupyter-Notebook durchgeführt werden. Dieses soll schliesslich auch abgegeben werden und dem Fachexperten erlauben, die Schritte nachzuvollziehen (allenfalls auch das Training erneut laufen zu lassen).

Beurteilung

Beurteilt wird auf Basis des abgegebenen Notebooks:

- Vollständige und korrekte Umsetzung der oben beschriebenen Aufgabestellung (Implementierung im DL-Framework Deiner Wahl, Untersuchung der verschiedenen Varianten).
- Gut gewählte und gut kommentierten Plots und Tabellen.
- Schlüssige Beschreibung und Interpretation der Ergebnisse.